

Aprendizado por reforço no Mundo de Wumpus

Implementação de Q-Learning com análise de transferência de aprendizado

O Mundo de Wumpus é um ambiente clássico da inteligência artificial, proposto em 1973, que consiste em um tabuleiro 4x4 onde um agente precisa encontrar um tesouro e retornar ao ponto de partida (posição 1,1), desviando de poços e do monstro Wumpus. Para resolver esse problema, o ambiente foi modelado utilizando aprendizado por reforço.

As ações que o agente pode escolher são: ir para cima, baixo, esquerda ou direita. Quanto ao estado atual, ele foi definido pela sua posição no tabuleiro combinada a um indicador de posse do tesouro, resultando em um espaço de 32 estados possíveis.

Para guiar o comportamento do agente, o sistema de recompensas foca tanto na sobrevivência quanto na conclusão da missão. Dessa forma, o agente recebe +10 ao coletar o ouro e mais +10 ao retornar ao início com ele. Por outro lado, cair em um poço ou ser pego pelo Wumpus encerra o episódio com uma penalidade de -10. Além disso, a fim de evitar que o agente ande em círculos ou faça caminhos desnecessariamente longos, cada passo em uma célula segura custa -0,5. Por fim, casas adjacentes a poços ou ao Wumpus possuem penalidades de -2,0 e -1,5, respectivamente, ensinando o agente a reconhecer o perigo e recuar antes de um movimento fatal.

A inteligência do agente foi construída com o algoritmo Q-Learning, utilizando a estratégia ϵ -greedy para balancear a exploração de novos caminhos com a escolha baseada nos conhecimentos já adquiridos. Para os parâmetros, a taxa de exploração começa em 1,0 (movimentos totalmente aleatórios no início) e vai decaindo ao longo dos episódios até atingir o mínimo de 0,05. O treinamento é considerado concluído se o agente conseguir vencer 10 episódios consecutivos, existindo um limite de 5.000 episódios para evitar loops infinitos.

O grande objetivo dessa implementação foi analisar a transferência de aprendizado entre dois mapas com configurações bem distintas. Primeiro, o agente foi treinado no mundo 1 (com o Wumpus na posição [1,3], poços espalhados e o ouro em [2,3]). Usando uma taxa de aprendizado de 0,15, fator de desconto de 0,9 e decaimento de 0,997, ele convergiu rápido, em apenas 570 episódios, encontrando um caminho seguro para resolver o problema.

Em seguida, o agente foi colocado em um novo tabuleiro (desconhecido pelo agente), que tinha uma disposição de perigos diferente a do mundo original (o Wumpus foi para a linha 4 e o ouro para o canto oposto, em [4,4]). Em vez de começar do zero, aprendendo tudo novamente, o agente importou a tabela Q aprendida no mundo 1. O resultado observado foi que houve transferência negativa, pois como as áreas que eram seguras no primeiro mapa agora abrigavam poços, o conhecimento prévio atrapalhou o agente a chegar no seu objetivo.

Desse modo, para que ele conseguisse desaprender os caminhos antigos e se adaptar à nova realidade, tive que reajustar os hiperparâmetros. Aumentei o alpha para 0,50, o que permitiu que ele sobrescrevesse os valores herdados incorretos com mais velocidade. Também resetei o epsilon para 1,0 e usei um decaimento mais lento (0,999), forçando o

agente a ter mais tempo para explorar o novo mundo. Com esses ajustes, ele conseguiu convergir no mundo 2, mas precisou de 1.428 episódios (2,5 vezes mais tempo que no Mundo 1), descobrindo uma nova rota pelas bordas direita e superior do mapa.

Sob essa análise, a principal questão desse exercício é que a transferência de aprendizado em ambientes que mudam não pode ser resumido a apenas aproveitar a Q-table da etapa de aprendizado. Se o cenário muda de maneira brusca, é essencial ajustar os mecanismos de aprendizado para que o agente consiga corrigir seus vieses antigos.

Saída do código:

```

** -----
Aprendendo o primeiro mundo
-----
+---+---+---+---+
|   |   |   | P |
+---+---+---+---+
| P |   | P |   |
+---+---+---+---+
|   |   | O |   |
+---+---+---+---+
| I |   | W |   |
+---+---+---+---+
O que as letras representam?: [I] Início [O] Ouro [W] Wumpus [P] Poço

Treinando o algoritmo no primeiro mundo
Episódio   500 | epsilon=0.2226 | vitórias consecutivas=2

Conseguiu concluir: True | Episódios necessários: 570
Simulação final no Mundo 1:
Atingiu o objetivo pelo caminho: [(1, 1), (2, 1), (2, 2), (2, 3), (2, 2), (2, 1), (1, 1)]
Ações: ['Cima', 'Direita', 'Direita', 'Esquerda', 'Esquerda', 'Baixo']

-----
Aprendendo a andar no segundo mundo
-----
+---+---+---+---+
| W |   |   | O |
+---+---+---+---+
|   |   |   |   |
+---+---+---+---+
|   | P |   |   |
+---+---+---+---+
| I |   |   | P |
+---+---+---+---+
O que as letras representam?: [I] Início [O] Ouro [W] Wumpus [P] Poço

Tentando usar algo do aprendizado do mundo 1.
O epsilon foi reiniciado em 1.0
e o alpha aumentado para 0.5 (sobrescreve valores antigos mais rápido).
A tabela Q do Mundo 1 foi usada como ponto de partida

Episódio   500 | epsilon=0.6064 | vitórias consecutivas=0
Episódio  1000 | epsilon=0.3677 | vitórias consecutivas=0

Conseguiu concluir: True | Episódios necessários: 1428
Simulação final no Mundo 2:
Atingiu o objetivo pelo caminho: [(1, 1), (1, 2), (1, 3), (2, 3), (3, 3), (4, 3), (4, 4), (3, 4), (2, 4), (2, 3), (1, 3), (1, 2), (1, 1)]
Ações: ['Direita', 'Direita', 'Cima', 'Cima', 'Cima', 'Direita', 'Baixo', 'Baixo', 'Esquerda', 'Baixo', 'Esquerda', 'Esquerda']

-----
Comparação
-----
Mundo 1:   570 episódios | Conseguiu concluir: True
Mundo 2:  1428 episódios | Conseguiu concluir: True

A conclusão é que tivemos transferência negativa.
O agente concluiu nos dois mundos, mas precisou de 858 episódios
a mais no Mundo 2 (1428 vs 570).
O conhecimento prévio interferiu, mas foi superado pela re-exploração.

```

